

ajuste_modelos

2026-06-03

Ler o banco de dados

```
url <- "https://raw.githubusercontent.com/juliafolgueral/me623-reg-trabfinal/main/dados_vinho.csv"
dados <- read.csv(url)
```

```
str(dados) # verificar tipos de variaveis
```

```
## 'data.frame': 6497 obs. of 13 variables:
## $ fixed.acidity : num 7.4 7.8 7.8 11.2 7.4 7.4 7.9 7.3 7.8 7.5 ...
## $ volatile.acidity : num 0.7 0.88 0.76 0.28 0.7 0.66 0.6 0.65 0.58 0.5 ...
## $ citric.acid : num 0 0 0.04 0.56 0 0 0.06 0 0.02 0.36 ...
## $ residual.sugar : num 1.9 2.6 2.3 1.9 1.9 1.8 1.6 1.2 2 6.1 ...
## $ chlorides : num 0.076 0.098 0.092 0.075 0.076 0.075 0.069 0.065 0.073 0.071 ...
## $ free.sulfur.dioxide : num 11 25 15 17 11 13 15 15 9 17 ...
## $ total.sulfur.dioxide: num 34 67 54 60 34 40 59 21 18 102 ...
## $ density : num 0.998 0.997 0.997 0.998 0.998 ...
## $ pH : num 3.51 3.2 3.26 3.16 3.51 3.51 3.3 3.39 3.36 3.35 ...
## $ sulphates : num 0.56 0.68 0.65 0.58 0.56 0.56 0.46 0.47 0.57 0.8 ...
## $ alcohol : num 9.4 9.8 9.8 9.8 9.4 9.4 9.4 10 9.5 10.5 ...
## $ quality : int 5 5 5 6 5 5 5 7 7 5 ...
## $ type : chr "Red" "Red" "Red" "Red" ...
```

```
dados$type <- as.factor(dados$type) # transformar tipo em fator
```

Modelo 01 - Com todas as variáveis

```
mod1 <- lm(quality ~ ., data = dados)
```

```
summary(mod1)
```

```
##
## Call:
## lm(formula = quality ~ ., data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7796 -0.4671 -0.0444  0.4561  3.0211
```

```
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1.048e+02  1.414e+01   7.411 1.42e-13 ***
## fixed.acidity    8.507e-02  1.576e-02   5.396 7.05e-08 ***
## volatile.acidity -1.492e+00  8.135e-02 -18.345 < 2e-16 ***
## citric.acid     -6.262e-02  7.972e-02  -0.786  0.4322
## residual.sugar   6.244e-02  5.934e-03  10.522 < 2e-16 ***
## chlorides       -7.573e-01  3.344e-01  -2.264  0.0236 *
## free.sulfur.dioxide 4.937e-03  7.662e-04   6.443 1.25e-10 ***
## total.sulfur.dioxide -1.403e-03  3.237e-04  -4.333 1.49e-05 ***
## density         -1.039e+02  1.434e+01  -7.248 4.71e-13 ***
## pH              4.988e-01  9.058e-02   5.506 3.81e-08 ***
## sulphates        7.217e-01  7.624e-02   9.466 < 2e-16 ***
## alcohol          2.227e-01  1.807e-02  12.320 < 2e-16 ***
## typeWhite       -3.613e-01  5.675e-02  -6.367 2.06e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7331 on 6484 degrees of freedom
## Multiple R-squared:  0.2965, Adjusted R-squared:  0.2952
## F-statistic: 227.8 on 12 and 6484 DF, p-value: < 2.2e-16
```

Interpretação do Teste F:

$H_0: \beta_1 = \beta_2 = \dots = \beta_{12} = 0$ H_1 : pelo menos um β é diferente de zero

p-valor < 0.05, logo, rejeitamos H_0 . Então existe evidência de que pelo menos uma variável físico-química está associada à qualidade do vinho.

R quadrado:

Cerca de 30% da variabilidade da qualidade é explicada pelas variáveis do banco.

Variáveis não significativas:

Olhando os p-valores, apenas a variável citric.acid (p-valor = 0.4) não é significativa. Depois de controlar pelas demais variáveis, o ácido cítrico não adiciona informação relevante para explicar a qualidade.

Variáveis com maior associação:

Olhando os valores absolutos da estatística observada t, as variáveis mais fortemente associadas à qualidade são: - volatile.acidity - alcohol - residual.sugar - sulphates

Interpretação dos coeficientes:

- Alcool: coef = 0.2227 e p-valor « 0.05 Mantida as demais variáveis fixas, um aumento de 1 unidade percentual de álcool está associado a um aumento médio de 0.2227 pontos na nota do vinho.
- Acidez volátil: coef = - 1.492 Mantidas as demais variáveis constantes, um aumento de 1 unidade na acidez volátil reduz a qualidade em média em 1.49.

- Sulfatos: coef = 0.722 Mantidas as demais variáveis constantes, maior concentração de sulfatos está associada a maior qualidade.
- Cloretos: coef = -0.757 Mantidas as demais variáveis constantes, cloretos tendem a diminuir a qualidade.

Comparação entre vinho branco e tinto

Mantidas as demais variáveis constantes, vinhos brancos apresentam nota média aproximadamente 0.36 pontos menor que vinhos tintos, com p-valor altamente significativo ($2.06e^{-10}$), sugerindo que o tipo do vinho tem efeito próprio mesmo após controlar pelas características químicas.

Intercepto

Não possui interpretação clara, serve apenas para posicionar a reta.

Conclusão para o modelo 01:

A qualidade do vinho apresenta associação significativa com praticamente todas as características físico-químicas analisadas. Os fatores mais fortemente relacionados à qualidade são álcool (efeito positivo), acidez volátil (efeito negativo), açúcar residual (efeito positivo) e sulfatos (efeito positivo). O ácido cítrico não apresentou efeito significativo após o ajuste pelas demais variáveis. Além disso, mesmo controlando pelas características químicas, vinhos brancos tendem a apresentar qualidade média inferior à dos tintos.

Modelo 02: Sem acido cítrico

Como o acido cítrico não foi significativo, vamos retirá-lo do modelo e verificar se perdemos capacidade explicativa ao retirar uma variável aparentemente irrelevante

```
mod2 <- lm(quality ~ fixed.acidity + volatile.acidity + residual.sugar + chlorides +
           free.sulfur.dioxide + total.sulfur.dioxide + density + pH + sulphates +
           alcohol + type, data = dados)

summary(mod2)
```

```
##
## Call:
## lm(formula = quality ~ fixed.acidity + volatile.acidity + residual.sugar +
##      chlorides + free.sulfur.dioxide + total.sulfur.dioxide +
##      density + pH + sulphates + alcohol + type, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7708 -0.4696 -0.0418  0.4540  3.0202
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1.054e+02  1.411e+01   7.471 9.02e-14 ***
## fixed.acidity    8.244e-02  1.541e-02   5.351 9.02e-08 ***
## volatile.acidity -1.471e+00  7.670e-02 -19.180 < 2e-16 ***
```

```
## residual.sugar      6.256e-02  5.932e-03  10.548 < 2e-16 ***
## chlorides          -8.007e-01  3.298e-01  -2.428  0.0152 *
## free.sulfur.dioxide  4.941e-03  7.662e-04   6.449  1.21e-10 ***
## total.sulfur.dioxide -1.427e-03  3.222e-04  -4.428  9.66e-06 ***
## density            -1.046e+02  1.431e+01  -7.307  3.05e-13 ***
## pH                  5.044e-01  9.029e-02   5.587  2.40e-08 ***
## sulphates           7.186e-01  7.614e-02   9.439 < 2e-16 ***
## alcohol             2.210e-01  1.794e-02  12.315 < 2e-16 ***
## typeWhite          -3.655e-01  5.651e-02  -6.468  1.07e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7331 on 6485 degrees of freedom
## Multiple R-squared:  0.2965, Adjusted R-squared:  0.2953
## F-statistic: 248.4 on 11 and 6485 DF,  p-value: < 2.2e-16
```

Os resultados encontrados no modelo 2 são muito próximos dos encontrados no modelo 01. Isso indica que 'ácido cítrico' de fato não tem grandes influências no modelo. Nesse caso, escolheríamos usar o modelo mais simples e excluimos essa variável do modelo.

```
car::vif(mod2)
```

```
##          fixed.acidity    volatile.acidity    residual.sugar
##          4.821499         1.927377          9.627472
##          chlorides    free.sulfur.dioxide    total.sulfur.dioxide
##          1.613873         2.235584          4.009422
##          density              pH          sulphates
##          22.259445         2.547400          1.551607
##          alcohol              type
##          5.535144         7.162425
```

Modelo 03: Modelo sem densidade

Tiramos a densidade, pois apesar de ser significativo, tem um vif alto, indicando uma possível multicolinearidade.

```
mod3 <- lm( quality ~ fixed.acidity + volatile.acidity + residual.sugar + chlorides +
  free.sulfur.dioxide + total.sulfur.dioxide + pH + sulphates +
  alcohol + type, data = dados)

summary(mod3)
```

```
##
## Call:
## lm(formula = quality ~ fixed.acidity + volatile.acidity + residual.sugar +
##     chlorides + free.sulfur.dioxide + total.sulfur.dioxide +
##     pH + sulphates + alcohol + type, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.8182 -0.4661 -0.0328  0.4601  3.0856
```

```
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    2.3290296  0.3081713   7.558 4.67e-14 ***
## fixed.acidity  -0.0062083  0.0095332  -0.651  0.51492
## volatile.acidity -1.5271972  0.0766209 -19.932 < 2e-16 ***
## residual.sugar   0.0227506  0.0023547   9.662 < 2e-16 ***
## chlorides       -1.0738019  0.3290182  -3.264  0.00111 **
## free.sulfur.dioxide 0.0056129  0.0007637   7.349 2.24e-13 ***
## total.sulfur.dioxide -0.0018006  0.0003194  -5.637 1.80e-08 ***
## pH              0.1008600  0.0717131   1.406  0.15964
## sulphates       0.5794362  0.0740134   7.829 5.71e-15 ***
## alcohol         0.3338912  0.0091500  36.491 < 2e-16 ***
## typeWhite       -0.1449695  0.0479694  -3.022  0.00252 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.736 on 6486 degrees of freedom
## Multiple R-squared:  0.2907, Adjusted R-squared:  0.2896
## F-statistic: 265.8 on 10 and 6486 DF, p-value: < 2.2e-16
```

```
car::vif(mod3)
```

```
##      fixed.acidity    volatile.acidity    residual.sugar
##      1.831573         1.908076         1.504948
##      chlorides free.sulfur.dioxide total.sulfur.dioxide
##      1.593157         2.203410         3.908395
##      pH            sulphates         alcohol
##      1.594221         1.454488         1.428123
##      type
##      5.120182
```

Modelo 2: Obtido por seleção de variáveis. Apresentou o melhor desempenho preditivo entre os modelos ajustados, com $R_{aj}^2 = 0,2953$. Entretanto, foram observados indícios de multicolinearidade, principalmente envolvendo as variáveis *density*, *residual.sugar* e *alcohol*.

Modelo 3: Ajustado sem a variável *density*, visando reduzir a multicolinearidade. Houve pequena perda de ajuste ($R_{aj}^2 = 0,2896$), mas os valores de VIF diminuíram consideravelmente, tornando o modelo mais adequado para interpretação dos coeficientes.

Os resultados indicam que maiores valores de *alcohol*, *sulphates* e *residual.sugar* estão associados a maiores níveis de qualidade, enquanto maiores valores de *volatile.acidity*, *chlorides* e *total.sulfur.dioxide* estão associados a menores níveis de qualidade. As variáveis *fixed.acidity* e *pH* não apresentaram significância estatística no Modelo 3.